

Predicting Student Health Risk

가이드 프로젝트 EDA

E조) 김영래 나현서 박가현 이건희

데이터 개요

Train shape: (690088, 15)

Test shape: (295753, 14)

	id	health_condition	...	smoking_alcohol	gender
0	0	unhealthy	...	yes	female
1	1	at-risk	...	yes	other
2	2	unhealthy	...	yes	male
3	3	unhealthy	...	occasional	female
4	4	at-risk	...	NaN	male

데이터 규모

- train.csv: 약 69만 건, test.csv 약 29만 건

변수 구성


- 수치형 7개 + 범주형 6개

예측 목표


- health_condition을 fit / at-risk / unhealthy 3개 클래스로 분류

타겟 변수 분포

At-risk 클래스 약 85.9% 차지
→ 타겟 클래스 간 **뚜렷한 불균형** 존재




수치형 변수 EDA




sleep_duration

건강 상태별 차이 가장 뚜렷



BMI

fit ↓ / unhealthy ↑



step_count


fit 그룹에서 상대적 높음

⇒ fit 그룹은 다른 그룹에 비해 긴 수면 시간, 낮은 BMI, 많은 걸음 수를 보였다.


범주형 변수 EDA



stress_level low: fit ↑ / high unhealthy ↑



physical_activity_level active: fit ↑



sleep_quality good: fit ↑ / poor: unhealthy ↑

⇒ 낮은 스트레스, 좋은 수면의 질,
높은 활동 수준에서
fit 비중이 상대적으로 높게 나타났다.

데이터 전처리

feature 선택

1. 식별자 id 제외
2. EDA·Feature Importance 바탕으로 예측력 낮은 4개 변수 제거
 - gender · diet_type · heart_rate · water_intake

결측치 처리

1. 수치형 결측치 원본 유지 또는 Median 대치
2. 결측 자체 정보 보존 위해 Indicator / "Missing" 범주 활용

인코딩

1. 범주형 변수는 Label Encoding 또는 One-Hot Encoding

이상치 처리

1. Boxplot / IQR 통해 극단값 확인
 - 비현실적이거나 명백한 오류값 없어 별도 제거 X

파생변수 생성

sleep_duration x BMI

짧은 수면과 높은 BMI가 결합될 때의
건강 위험 패턴 반영

missing_count

한 행의 결측값 개수 자체를
새로운 정보로 활용

is_optimal_activity

걸음 수·운동 시간이 fit 그룹의
활동 범위에 속하는지 반영

UMAP / KMeans


주요 건강 변수의 잠재 군집 구조를
새로운 특성으로 활용

sleep × stress × BMI

수면, 스트레스, BMI가 동시에
작용하는 복합 건강 패턴 반영

주요 발견: BMI 결측 여부에 따른 건강 상태 분포

⇒ BMI 결측 여부 자체가 타겟과 연관된 정보를 가질 가능성 확인




BMI 관측

- fit 5.7 %
- unhealthy 8.5 %

BMI 결측

- fit 8.2 %
- unhealthy 2.9 %



BMI 결측 → sleep_quality 100% good

sleep_quality → BMI good에서만 발생

⇒ BMI 결측이 sleep_quality와 연관된 비무작위 결측 패턴일 가능성