

가이드 프로젝트 E조

중간발표

김영래 나현서 박가현 이건희

Table of Contents


목차

01. 개별 모델링 내용

02. 공통 요소 설명

03. 향후 계획

개별 모델링 내용 1



최종 결과

[TE-HGBC 65% + FT-Transformer 35% 앙상블]

OOF	Public	Private
0.95040	0.95038	0.95092

- 합성 데이터 반복값 → Exact-value TE 활용
- 클래스 불균형 → Unweighted + Multiplier 보정
- 모델 다양성 활용 → 서로 오류 패턴 다른 HGBC + FT-Transformer 앙상블
- sleep_duration, stress_level 등의 핵심 변수 결측 → 성능 급락 확인 → 핵심 정보가 없는 행을 얼마나 잘 처리하는지가 중요

개별 모델링 내용 2

Logistic Regression



Random Forest



CatBoost



LightGBM



XGBoost



CatBoost + All-Feature Exact-value TE



CatBoost 60% + LightGBM 40% 앙상블

최종 결과

[CatBoost 60% + LightGBM 40% 앙상블]

3-Fold Balanced Accuracy	Public	Private
0.95016	0.94990	0.95021

- 반복값 구조 → All-Feature Exact-value TE 활용
- OOF 기반 재검증 → 안정적인 성능 개선 여부 확인
- 모델 다양성 활용 → CatBoost와 LightGBM 앙상블
- 숫자형 변수만 TE 적용시 효과 없음 → 전체 변수 TE로 성능 개선

개별 모델링 내용 3



최종 결과

[Exact-value Target Encoding + HGBC + BMI joint feature]

5-Fold Balanced Accuracy	Private
0.95001	0.9502

- 클래스 불균형 → Balanced Accuracy 중심 평가
- 반복값 정보 → Exact-value Target Encoding
- BMI 결측 패턴 → BMI x Sleep quality 파생변수
- 다수 feature 추가 대신 Ablation Test로 유효 변수 선택

개별 모델링 내용 4

CatBoost



LightGBM



XGBoost



TE-HGBC



RealMLP



FT-Transformer



TE-HGBC + RealMLP + FT-Transformer

최종 결과

[TE-HGBC + RealMLP + FT-Transformer (1:1:1)]

Private
0.95045



- 반복값 패턴 → Exact-value TE로 정밀 정보 활용
- GBDT 간 높은 예측 일치율 → 비슷한 모델 간 앙상블 효과 제한
- RealMLP, FT-Transformer 추가 → 서로 다른 오류 패턴 활용해 성능 개선
- 앙상블 모델 가중치 최적화는 과적합 → 단순 1:1:1 블렌딩이 가장 안정적

공통 요소 설명

Exact-value Target Encoding

- 같은 값을 가진 데이터들을 하나의 그룹으로 묶음
→ 그 그룹에서 각 클래스가 얼마나 자주 나오는지 계산
→ 계산한 비율을 새로운 변수로 만들어 모델에 추가
- 반복되는 값이 많은 데이터에서 유용하게 활용 가능

예) sleep_duration = 7.0인 사람들 중
at-risk 85% / fit 10% / unhealthy 5%
→ 이 비율을 새로운 정보로 사용!

Cross Validation / OOF

- 데이터를 한 번만 Train / Validation으로 나누지 않고
여러 번 나눠 평가
- 각 데이터가 한 번씩 validation 역할을 하도록 학습
- 모델이 처음 보는 데이터에서 얼마나 잘 맞추는지 반복
확인
→ 한 번의 validation 결과에 지나치게 의존하는 것을
줄여 안정적인 성능 검증이 가능하다.

공통 요소 설명

클래스 불균형 처리

- 이번 데이터는 at-risk가 약 86%로 대부분을 차지
→ Accuracy 대신 Balanced Accuracy 중심 평가
- class_weight로 학습 단계에서 보정 가능
- Class Multiplier로 예측 단계에서도 보정 가능

앙상블

- 여러 모델의 예측 확률을 결합
→ 단일 모델의 오류를 서로 보완
- 예측이 비슷한 유사 모델들은 앙상블 효과가 제한적
→ 서로 다른 구조와 오류 패턴의 모델들을 조합하는 게 더 효과적이다.

향후 계획

최고 성능 기록한
TE-HGBC +
RealMLP + FT-
Transformer (1:1:1)
을 기준 모델로 선정

팀원별 실험에서
효과 있었던 피처
엔지니어링 방법
추가 적용

결측치, 클래스
불균형 처리 방식
추가 실험

모델별 오류 패턴
분석 및 앙상블
조합 재검토

OOF 기반 성능
검증 후 최종 모델
고도화

들어주셔서 감사합니다.

**THANK
YOU**
